

Занятие 5. Диффузия и score: тот же transport landscape, но не «то же самое» без условий

Как Gaussian noising, score и Flow Matching описывают один transport landscape — и где equivalence заканчивается?

Автор: Андрей Ильинский, 2026

Orientation τ изменилась

занятие 4

 $\tau = 0$

source / noise

 $\tau = 1$

data

занятие 5

 $\tau = 0$

clean data

 $\tau = 1$

noise


generation

Token index t не меняется и в этой оси не участвует.

Gaussian corruption задаёт noise schedule

$$x_\tau = \alpha_\tau x_0 + \sigma_\tau \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

$$\begin{aligned} \alpha_0 &\approx 1, & \sigma_0 &\approx 0, \\ \alpha_1 &\approx 0, & \sigma_1 &\approx 1. \end{aligned}$$

signal $\alpha_\tau x_0$ noise $\sigma_\tau \epsilon$ 

Conditional mean

$$\begin{aligned}\mathbb{E}[X_\tau \mid x_0] &= \alpha_\tau x_0 + \sigma_\tau \mathbb{E}[\epsilon] \\ &= \alpha_\tau x_0.\end{aligned}$$

$$\mathbb{E}[\epsilon] = 0$$

Conditional covariance

$$X_\tau - \mathbb{E}[X_\tau \mid x_0] = \sigma_\tau \epsilon.$$

$$\begin{aligned} \text{Cov}(X_\tau \mid x_0) &= \sigma_\tau^2 \text{Cov}(\epsilon) \\ &= \sigma_\tau^2 I. \end{aligned}$$

Conditional corruption известен точно

$$p(x_\tau \mid x_0) = \mathcal{N}(\alpha_\tau x_0, \sigma_\tau^2 I).$$

known




conditional kernel

unknown

noisy marginal $p_\tau(x)$

Conditional Gaussian $\neq$ marginal Gaussian

$$p_{\tau}(x) = \int p_{\text{data}}(x_0) p(x | x_0) dx_0.$$



ядра вокруг разных чистых сэмплов



сложный marginal, не гауссов

условное ядро известно; интеграл по данным — нет

Нужна local geometry неизвестного p_τ

Какой объект можно учить по tractable conditional corruption?

Score — gradient log-density

$$s_{\tau}(x) = \nabla_x \log p_{\tau}(x).$$

$$\nabla_x \log p(x) = \frac{\nabla_x p(x)}{p(x)}.$$



Conditional Gaussian score

$$\nabla_{x_\tau} \log p(x_\tau \mid x_0) = - \frac{x_\tau - \alpha_\tau x_0}{\sigma_\tau^2}.$$

Подсвечено displacement: насколько зашумлённая точка ушла от масштабированных данных.

Подставляем corruption noise

$$x_\tau - \alpha_\tau x_0 = \sigma_\tau \epsilon.$$

$$\nabla_{x_\tau} \log p(x_\tau \mid x_0) = -\frac{\epsilon}{\sigma_\tau}.$$

Одна степень σ_τ сократилась: остаётся первая.

Denoising identity

$$s_{\tau}(x) = \mathbb{E} [\nabla_x \log p(X_{\tau} = x \mid X_0) \mid X_{\tau} = x].$$

$$s_{\tau}(x) = -\frac{1}{\sigma_{\tau}} \mathbb{E}[\epsilon \mid X_{\tau} = x].$$

hidden conditional target

MSE

conditional mean

мотив занятия 4

Noise prediction даёт score

$$\mathcal{L}_\epsilon = \mathbb{E} \left[w_\epsilon(\tau) \|\hat{\epsilon}_\theta(X_\tau, \tau) - \epsilon\|_2^2 \right].$$

$$s_\tau(x) = -\frac{\hat{\epsilon}^*(x, \tau)}{\sigma_\tau}.$$

Параметризации

Одна и та же модель — четыре способа записать, что она предсказывает

Четыре target parameterizations

TARGET	NETWORK PREDICTS	CONVERSION	ТИП ОБЪЕКТА
ϵ	noise	$\hat{s} = -\hat{\epsilon}/\sigma_\tau$	conditional denoising target
x_0	clean sample	$\hat{x}_0 = (x_\tau - \sigma_\tau \hat{\epsilon})/\alpha_\tau$	clean-data parameterization
score	$s_\tau(x)$	$\hat{\epsilon} = -\sigma_\tau \hat{s}$	marginal density geometry
v^{VP}	$\alpha_\tau \epsilon - \sigma_\tau x_0$	rotation with (x_τ, v^{VP})	diffusion target parameterization

Из noise prediction в clean prediction


$$\hat{x}_0 = \frac{x_\tau - \sigma_\tau \hat{\epsilon}_\theta}{\alpha_\tau}.$$

$$\hat{x}_0 = \frac{x_\tau + \sigma_\tau^2 \hat{s}_\tau}{\alpha_\tau}.$$

v -prediction — rotation, не ODE arrow

$$v_{\tau}^{\text{VP}} = \alpha_{\tau}\epsilon - \sigma_{\tau}x_0.$$

$$\begin{aligned} x_{\tau} &= \alpha_{\tau}x_0 + \sigma_{\tau}\epsilon, \\ v_{\tau}^{\text{VP}} &= -\sigma_{\tau}x_0 + \alpha_{\tau}\epsilon. \end{aligned}$$



Inverse transform

$$\begin{aligned}x_0 &= \alpha_\tau x_\tau - \sigma_\tau v_\tau^{\text{VP}}, \\ \epsilon &= \sigma_\tau x_\tau + \alpha_\tau v_\tau^{\text{VP}}.\end{aligned}$$

Преобразование обратимо: информация не теряется ни в одну сторону.

Три разных объекта с буквой velocity

 v_{τ}^{VP} 

target

diffusion target: координата, не поле

 U_{τ} 

conditional velocity одного пути

 $v_{\tau}(x)$ 

marginal ODE vector field

$$U_{\tau} = \dot{\alpha}_{\tau} X_0 + \dot{\sigma}_{\tau} \epsilon.$$

$$v_{\tau}^{\text{VP}} = \alpha_{\tau} \epsilon - \sigma_{\tau} X_0.$$

Связь с занятием 4

При каких условиях диффузия и flow matching описывают одно и то же?

Когда conditional velocity proportional v -prediction

$$\alpha_\tau = \cos \phi_\tau, \quad \sigma_\tau = \sin \phi_\tau.$$

$$U_\tau = \dot{\phi}_\tau v_\tau^{\text{VP}}.$$

$$\phi_\tau = \frac{\pi\tau}{2} \implies U_\tau = \frac{\pi}{2} v_\tau^{\text{VP}}.$$

Proportional $\neq$ identical by definition.

Invertible targets $\neq$ одинаковая loss

$$\|\hat{s} - s^{\text{cond}}\|_2^2 = \frac{1}{\sigma_\tau^2} \|e_\epsilon\|_2^2.$$

Множитель зависит от времени: это weighting, а не другая задача.

x_0 -MSE меняет weighting по времени

$$\|\hat{x}_0 - x_0\|_2^2 = \frac{\sigma_\tau^2}{\alpha_\tau^2} \|e_\epsilon\|_2^2.$$

Тот же остаток e_ϵ , другой множитель.

v -MSE тоже имеет свой scale

$$\|\hat{v} - v_{\tau}^{\text{VP}}\|_2^2 = \frac{1}{\alpha_{\tau}^2} \|e_{\epsilon}\|_2^2.$$


Одинаковые задачи с разными весами — не одинаковое обучение.

Score можно превратить в deterministic transport


Как diffusion path возвращается к vector field занятия 4?

SDE, reverse SDE и probability-flow ODE — разные dynamics

$$dX_\tau = f(X_\tau, \tau)d\tau + g(\tau)dW_\tau.$$



stochastic trajectories



deterministic trajectories, те же time marginals

$$\frac{dx}{d\tau} = f(x, \tau) - \frac{1}{2}g(\tau)^2 s_\tau(x).$$

Marginal score $\leftrightarrow$ marginal transport velocity

$$\begin{aligned} v_\tau(x) &= \frac{\dot{\alpha}_\tau}{\alpha_\tau} x \\ -\sigma_\tau \left(\dot{\sigma}_\tau - \frac{\dot{\alpha}_\tau}{\alpha_\tau} \sigma_\tau \right) s_\tau(x). \end{aligned}$$

probability-flow ODE field = marginal FM field.

Четыре уровня equivalence

targets algebraically convertible

ideal marginal fields can describe same path

losses equal only after weighting alignment

finite trained networks need not coincide

DiT разводит generative construction и backbone

Path / objective	Backbone	Sampler
Gaussian corruption	U-Net	reverse stochastic sampler
ϵ target	Transformer	probability-flow ODE
score target	linear-attention Transformer	solver schedule
v target	hybrid	

Любую ось можно поменять, не меняя две другие.

Score — градиент логарифма плотности. Не градиент плотности.

Diffusion — один transport landscape, но несколько разных statements



Следующий вопрос: что из этой construction survives, если state — categorical tokens без Euclidean geometry?