

Занятие 6. Диффузия для текста: сначала discrete bridge, потом LLaDA

Что остаётся от diffusion и Flow Matching, когда state — categorical tokens без естественной Euclidean geometry?

Автор: Андрей Ильинский, 2026

Что ломается при переходе к tokens



механический
перенос score




градиент требует окрестности; у категории её нет

Permutation test для token geometry

до permutation



после permutation



Данные те же. «Близость» токенов изменилась только из-за нумерации.

Gaussian kernel на ids зависит от arbitrary labels

$$q_{\sigma}(v' | v) \propto \exp \left(-\frac{(c(v') - c(v))^2}{2\sigma^2} \right).$$

$$q_{\sigma,\pi}(v' | v) \propto \exp \left(-\frac{(\textcolor{yellow}{c}_{\pi}(v') - \textcolor{yellow}{c}_{\pi}(v))^2}{2\sigma^2} \right).$$

$$q_{\sigma,\pi}(v' | v) \neq q_{\sigma}(v' | v).$$

Модель меняется от переобозначения словаря — значит, она опирается не на язык.


One-hot убирает geometry ids, но не создаёт smooth density

$$\mu = \sum_{v \in \mathcal{V}} p(v) \delta_{e_v}.$$



Gaussian smoothing one-hot — уже другая continuous model

$$p_{\sigma}(z) = \sum_{v \in \mathcal{V}} p(v) \mathcal{N}(z; e_v, \sigma^2 I).$$



гауссовы облака вокруг вершин

Valid construction, но state теперь непрерывный z , а не токен.

Для categories естественнее забывать значение, а не двигать его по ids

Как задать corruption без выбранной Euclidean geometry?

Masked / absorbing-state corruption

$$\bar{\mathcal{V}} = \mathcal{V} \cup \{\text{MASK}\}.$$


$$q_{\tau}(\tilde{x}_{\tau,t} \mid x_t) = (1 - \rho_{\tau})\mathbf{1}[\tilde{x}_{\tau,t} = x_t] + \rho_{\tau}\mathbf{1}[\tilde{x}_{\tau,t} = \text{MASK}].$$

$$\tilde{X}_1 = (\text{MASK}, \dots, \text{MASK}).$$

Сколько masks в sequence

$$I_{\tau,t} \sim \text{Bernoulli}(\rho_{\tau}), \quad N_{\text{mask},\tau} = \sum_{t=1}^T I_{\tau,t}.$$

$$N_{\text{mask},\tau} \sim \text{Binomial}(T, \rho_{\tau}).$$



Forward masking и reverse unmasking

forward masking, растущее t




generation, убывающее t



те же позиции: меняется только, какие раскрыты

Learned object — probability denoiser



$$D_{\theta}(v \mid z, \tau) \approx \Pr(X_0 = v \mid X_{\tau} = z).$$

Masked-token CE ещё не делает model diffusion

Что добавляют probability path, weighting и reverse sampler?

MDLM: weighted family masked-token losses

$$\mathcal{L} = \mathbb{E}_{\tau, X, \tilde{X}_\tau} \left[w(\tau) \sum_{t: \tilde{x}_{\tau, t} = \text{MASK}} -\log p_\theta(x_t \mid \tilde{X}_\tau, \tau) \right].$$

случайные clean data

случайный уровень τ

случайный mask pattern

MDLM weight через masking probability

$$w_{\text{MDLM}}(\tau) = \frac{\dot{\kappa}_{\tau}}{\kappa_{\tau} - 1}.$$

$$w_{\text{MDLM}}(\tau) = \frac{\dot{\rho}_{\tau}}{\rho_{\tau}}.$$

$$w_{\text{MDLM}}(\tau) = \frac{1}{\tau}.$$

Заменяли keep probability на mask probability; для линейного расписания вес равен $1/\tau$.

MDLM — не просто BERT с другим mask rate


ПРИЗНАК	BERT-STYLE MLM	MASKED DIFFUSION / MDLM	ПОЧЕМУ ВАЖНО
Noise level	фиксированный corruption regime	random τ , continuum mask rates	точки probability path
Weighting	обычный CE на selected positions	$w_{\text{MDLM}}(\tau)$	часть diffusion objective
Generation	reverse process не задан objective	denoiser встроен в reverse sampler	model definition включает sampling
Initial generation state	обычно наблюдаемый текст	all-mask state	generation идёт noisy $\rightarrow$ clean

Flow Matching survives без Euclidean velocity

Что заменяет vector field в discrete state space?

Transition rate — не probability одного шага

$$\Pr(X_{\tau+h} = y \mid X_{\tau} = x) = r_{\tau}(x \rightarrow y)h + o(h), \quad y \neq x.$$



Probability в state меняется как incoming minus outgoing

outgoing loss


$$p_{\tau}(x) \left(1 - h \sum_{y \neq x} r_{\tau}(x \rightarrow y) \right)$$

incoming gain

$$\sum_{y \neq x} p_{\tau}(y) r_{\tau}(y \rightarrow x) h$$


Master equation

$$\partial_{\tau} p_{\tau}(x) = \sum_{y \neq x} [p_{\tau}(y) r_{\tau}(y \rightarrow x) - p_{\tau}(x) r_{\tau}(x \rightarrow y)].$$



Total probability сохраняется

$$\partial_{\tau} \sum_x p_{\tau}(x) = 0.$$



масса перемещается между состояниями, но не исчезает


Continuous transport и discrete transport

CONTINUOUS	DISCRETE	РОЛЬ
$x \in \mathbb{R}^d$	$x \in \mathcal{S}$	state
$v_\tau(x)$	$r_\tau(x \rightarrow y)$	local transport law
spatial flux	transferred probability mass	flow
continuity equation	master equation	conservation
vector-field learning	denoiser / rates	learned object

LLaDA

Что значит, что masked diffusion удалось масштабировать?

LLaDA: один NFE предсказывает много positions




Parallel prediction $\neq$ one-pass generation



новое состояние прошлый forward не видел: нужен ещё один вызов

$$p_{\theta}(x_t \mid X^{(m)}), t \in \mathcal{M}_m, \quad \hat{x}_t^{(m)} \sim p_{\theta}(\cdot \mid X^{(m)}).$$

Почему AR KV cache exact




Почему full bidirectional dLLM cache становится stale

состояние 1



состояние 2



изменились и левое, и правое представление

изменённые hidden states поднимаются в K/V верхних слоёв

$$N_{\text{processed}} \approx L N_{\text{FE}}.$$

Block diffusion

Почему кэш возвращается туда, где он был не нужен?

Block diffusion меняет factorization

$$p(X) = \prod_{b=1}^B p(X^{(b)} \mid X^{(<b)}).$$





Block diffusion возвращает exact reusable past

completed blocks: immutable causal prefix



current block: mutable



Generative factorization → invariant past → cache correctness.

Fast-dLLM v2: hierarchical caching

1 — block-level cache завершённой истории

2 — sub-block reuse внутри частично раскрытого блока

параллельное декодирование в конвейере

**authors report up to 2.5× speedup
in their setup**

measurement, не теорема о классе моделей

**У токена нет градиента логарифма плотности.
Поэтому нужен не перенос конструкции, а другой
процесс порчи.**

Обе оси курса снова встретились

ось B — генеративная конструкция

ось A



$$\mathcal{C} = (M_{weights}, M_{persistent}, M_{workspace}, B_{HBM}, F, D_{seq}, N_{FE}, N_{processed}, B_{max}).$$